ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas
Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º 1

LECTURA DE DATOS

Estadística y Programación para Ciencia de Datos I · IDSD422

Campo	Información
Estudiante	Andrea Nicol Cumbal Gordón
Usuario de GitHub	andrea0119C
Docente	Christian Suárez
Período académico	2026-B
Fecha del informe	20/10/2026
Repositorio (fork)	https://github.com/andrea0119C/IDSD422-lab1-lectura-datos

Informe basado en la ejecución de los scripts Python y R de RetailAndina S. A., utilizando los archivos ventas.csv, ventas.json y ventas.xlsx.

1. Introducción

RetailAndina S. A. se encuentra en el desafío de recibir de forma semanal reportes de ventas provenientes de tres sistemas independientes a saber, el ERP de sucursales, la plataforma de fidelización y el área de Finanzas. Cada uno de estos reportes se presenta en uno de los formatos CSV, JSON o Excel, donde también se debe de verificar la comparabilidad de estos reportes antes de proceder a su consolidación. Y la gerencia requiere pegar un vistazo a la estructura del grupo de archivos y generar ciertos indicadores comerciales que le sirvan para apoyar una primera revisión de los resultados obtenidos.

En esta práctica, trabajé con los formatos anteriormente indicados en Python y R, inspeccionando las filas, las columnas y los tipos de datos y generando medidas descriptivas para cada archivo. También documenté las dificultades que fui encontrando para ejecutar el código a partir de Google Colab, Posit Cloud y VS Code.

2. Objetivos

Objetivo general. Analizar los reportes de ventas de RetailAndina S. A. en CSV, JSON y Excel mediante Python y R para verificar su estructura y obtener indicadores descriptivos.

Objetivos específicos.

- Leer los tres formatos en ambos lenguajes.
- Contrastar dimensiones, variables y tipos
- Calcular indicadores de ventas por sucursal y región
- Documentar procedimientos, dificultades y resultados reproducibles.

3. Desarrollo de la práctica

3.1. Lectura de formatos en Google Colab (Python)

Comencé cargando los archivos en Google Colab. Con pandas leí ventas.csv y verifiqué su estructura mediante head(), shape y dtypes. Obtuve cinco registros y cuatro variables: sucursal, region, ventas y clientes. Después transformé el JSON con json.load() y pd.json_normalize(); la tabla resultante mostró también cinco filas y cuatro columnas. Los tres reportes presentaron los mismos valores observados. Las capturas de Colab se presentan en los Anexos A y B.

```
ventas = pd.read_csv("data/ventas.csv")
print(ventas.shape); print(ventas.dtypes)
```

3.2. Lectura e inspección en Posit Cloud (R)

En Posit Cloud importé los reportes con las funciones de R y comprobé sus primeras filas, dimensiones y estructura. Para los datos categóricos identifiqué sucursal y región como variables de texto; ventas y clientes correspondieron a valores numéricos. Al comenzar apareció una instrucción incorrecta al intentar imprimir un objeto; revisé la función y repetí la ejecución. Las evidencias de esta etapa se muestran en los Anexos C y D.

```
ventas <- read.csv("data/ventas.csv")
str(ventas); head(ventas); dim(ventas)
```

3.3. Verificación de estructura y Calidad

Formato	Función en Python	Función en R	Filas × columnas
CSV	pd.read_csv()	read.csv()/read_csv()	5 × 4
JSON	json.load() + json_normalize()	jsonlite::fromJSON()	5 × 4
Excel	pd.read_excel()	readxl::read_excel()	5 × 4

CSV guarda texto delimitado; JSON representa objetos que pueden requerir aplanamiento; Excel utiliza hojas de cálculo. Los métodos de importación fueron diferentes, pero los registros recuperados coincidieron. Revisé los tipos porque una columna ventas interpretada como texto podría indicar símbolos, espacios o separadores inesperados que dificultarían los cálculos.

3.4. Implementación local en VS Code y GitHub

Tras las pruebas iniciales, completé en el repositorio los scripts leer_csv, leer_json, leer_excel e inspeccion, tanto en .py como en R. En VS Code contrasté los resultados con las pruebas en la nube. Las salidas locales de Python mostraron las mismas cinco filas y cuatro columnas. Para la ejecución desde la raíz del repositorio corresponde utilizar rutas relativas, por ejemplo data/ventas.csv, en lugar de rutas del equipo o de Colab. El repositorio conserva README.md, informe.md y .gitignore; el control de versiones permite registrar cada avance mediante commits descriptivos (Anexos E–J).

3.5. Inspección y cálculo de indicadores

Creé la variable ticket dividiendo ventas entre clientes para cada sucursal. Para obtener el ticket promedio general dividí la suma de las ventas entre la suma de clientes; no usé la media simple de los tickets individuales. También utilicé funciones de agrupación para encontrar las sucursales de mayor y menor venta y la región con el mayor acumulado (Anexos K–L).

```
ventas["ticket"] = ventas["ventas"] / ventas["clientes"]
promedio = ventas["ventas"].mean()
ticket_general = ventas["ventas"].sum() / ventas["clientes"].sum()
ventas_region = ventas.groupby("region")["ventas"].sum()
```

3.6. Resultados comerciales

Indicador	Resultado
Venta promedio por sucursal	12.008,00
Ticket promedio general	38,07
Sucursal con mayor venta	Guayaquil Centro: 15.200
Sucursal con menor venta	Cuenca: 8.540
Región con mayor venta total	Sierra: 30.860

Guayaquil Centro presentó las mayores ventas individuales, mientras que Cuenca registró las menores. La región Sierra sumó 30.860, frente a 29.180 de Costa. Los datos describen las cinco sucursales incluidas en el reporte de la semana 39 y no constituyen una predicción de períodos posteriores.

4. ¿Qué aprendí con esta práctica?

Aprendí a importar y contrastar una misma información desde formatos con estructuras distintas. Comprendí que un JSON puede necesitar normalización antes de tratarse como tabla y que las categorías se representan de forma diferente en Python y R. Además, identifiqué la diferencia entre calcular el promedio global y agrupar una sola observación por sucursal. Una dificultad fue la configuración de bibliotecas en R, que resolví instalándolas en una carpeta personal. También comprobé la importancia de utilizar rutas relativas: facilitan que otra persona ejecuté el proyecto sin cambiar los nombres de las carpetas. En una próxima práctica validaría desde el inicio cada archivo y conservaría las evidencias de las ejecuciones de manera ordenada.

5. Conclusiones

1. Los archivos CSV, JSON y Excel se visualizaron con cinco registros y cuatro columnas, con valores coincidentes después de realizar la lectura y, para JSON, la normalización. La comprobación de contenido es necesaria: comparar solo dimensiones no basta para validar un reporte.

2. Los tipos de datos fueron adecuados para las operaciones: sucursal y region son variables categóricas, mientras que ventas y clientes son cuantitativas. La venta promedio fue de 12.008 por sucursal y el ticket promedio general de 38,07.

3. Guayaquil Centro registró la mayor venta individual (15.200), Cuenca la menor (8.540) y Sierra el mayor total por región (30.860). Recomendaría a RetailAndina estandarizar nombres y tipos de columnas, utilizar CSV cuando convenga intercambiar tablas sencillas y validar valores faltantes, duplicados e inconsistencias. Los hallazgos corresponden exclusivamente al período analizado.

6. Bibliografía

pandas development team. (s. f.). pandas.read_csv. Documentación de pandas. https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

Wickham, H., & Bryan, J. (s. f.). readxl: Read Excel Files. https://readxl.tidyverse.org/

Ooms, J. (s. f.). jsonlite: A Simple and Robust JSON Parser and Generator for R. https://cran.r-project.org/package=jsonlite

Suárez, C. (2026). Laboratorio 1: Consolidación de reportes de ventas [Material de práctica de IDSD422, archivos CSV, JSON y Excel].

Declaración de uso de inteligencia artificial

Utilicé ChatGPT como apoyo para estructurar el informe, revisar su redacción y aclarar procedimientos de Python y R. Las capturas incorporadas corresponden a las ejecuciones compartidas de la práctica; revisé las explicaciones y los resultados antes de preparar el documento.

Repositorio del trabajo

https://github.com/andrea0119C/IDSD422-lab1-lectura-datos

Las evidencias originales y sus pies de figura se incluyen a continuación, fuera del cuerpo del informe.

Anexo A. Evidencias de ejecución

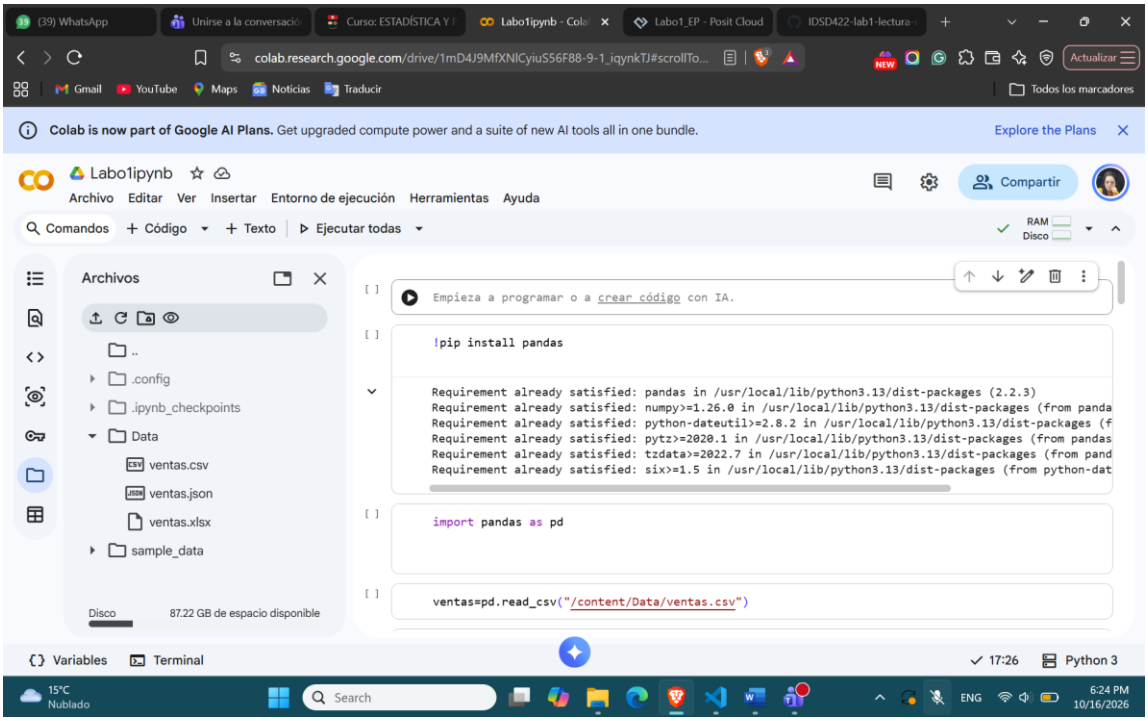


Figura 1. Google Colab: preparación de la carpeta de datos y lectura inicial del CSV.

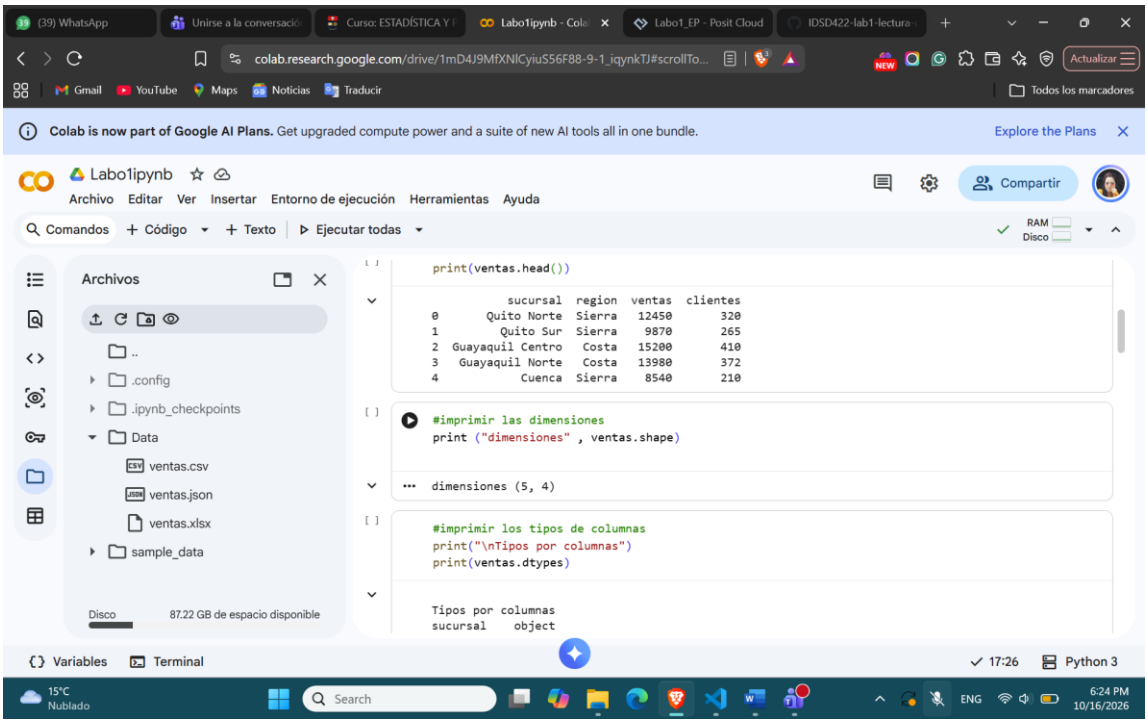


Figura 2. Google Colab: salida del CSV, dimensiones y exploración de columnas.

Anexo B. Evidencias de ejecución

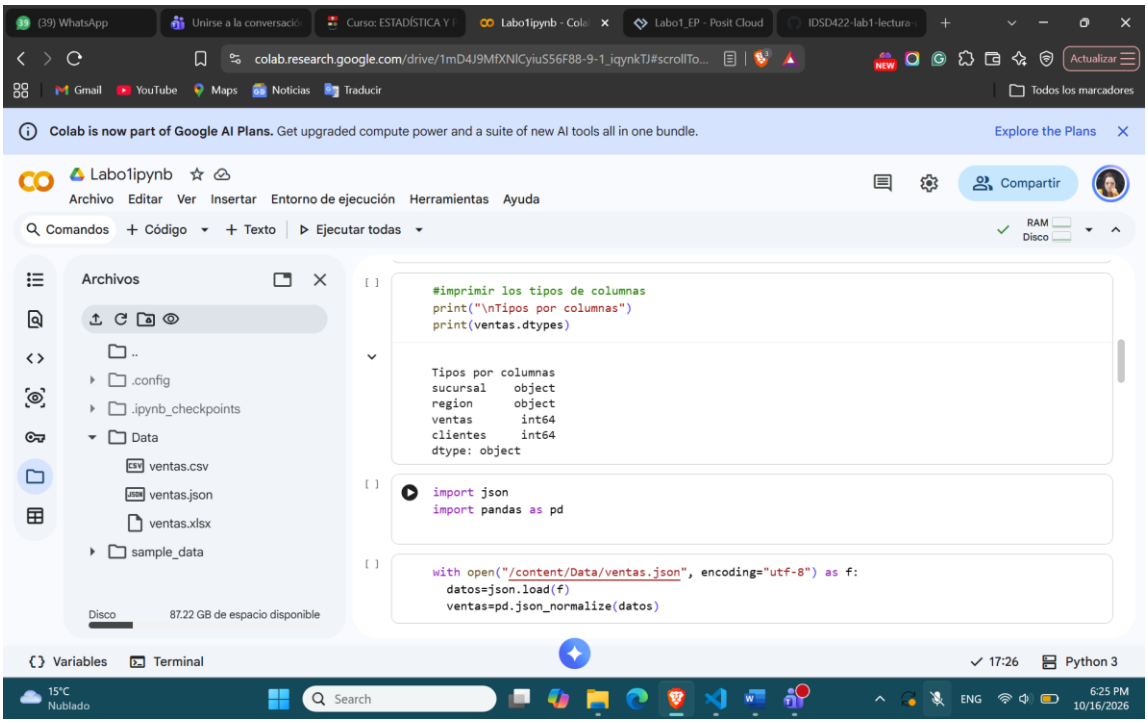


Figura 3. Google Colab: inspección de tipos y carga del archivo JSON.

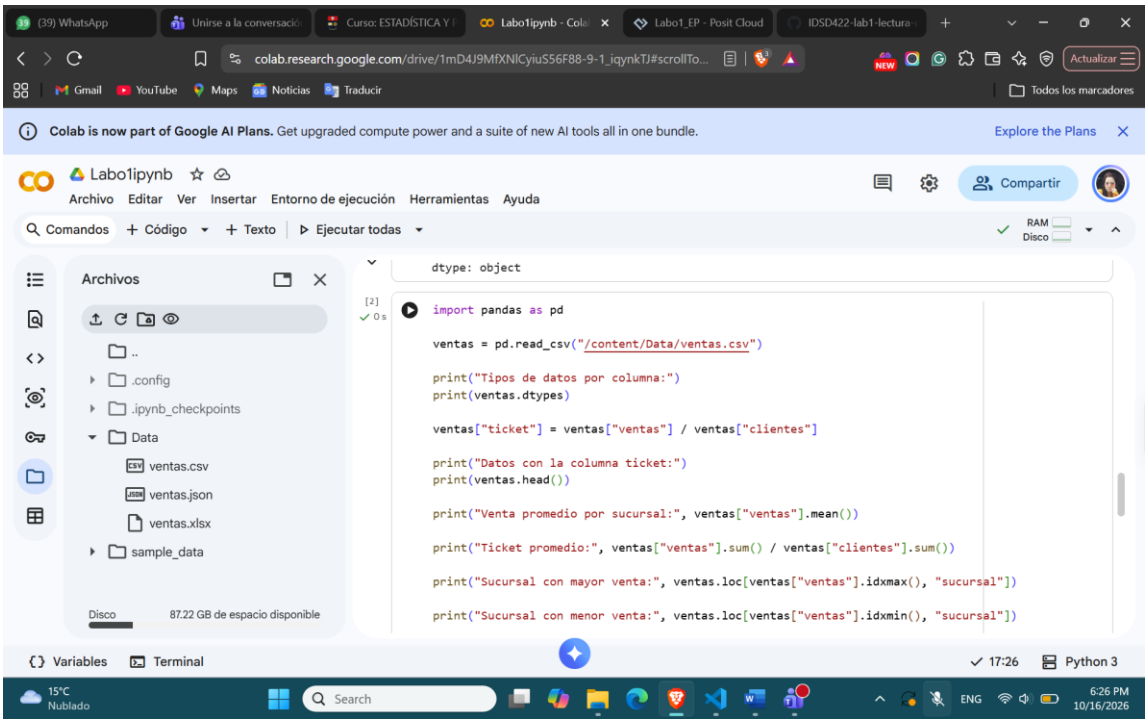


Figura 4. Google Colab: código de inspección y preparación de indicadores.

Anexo C. Evidencias de ejecución

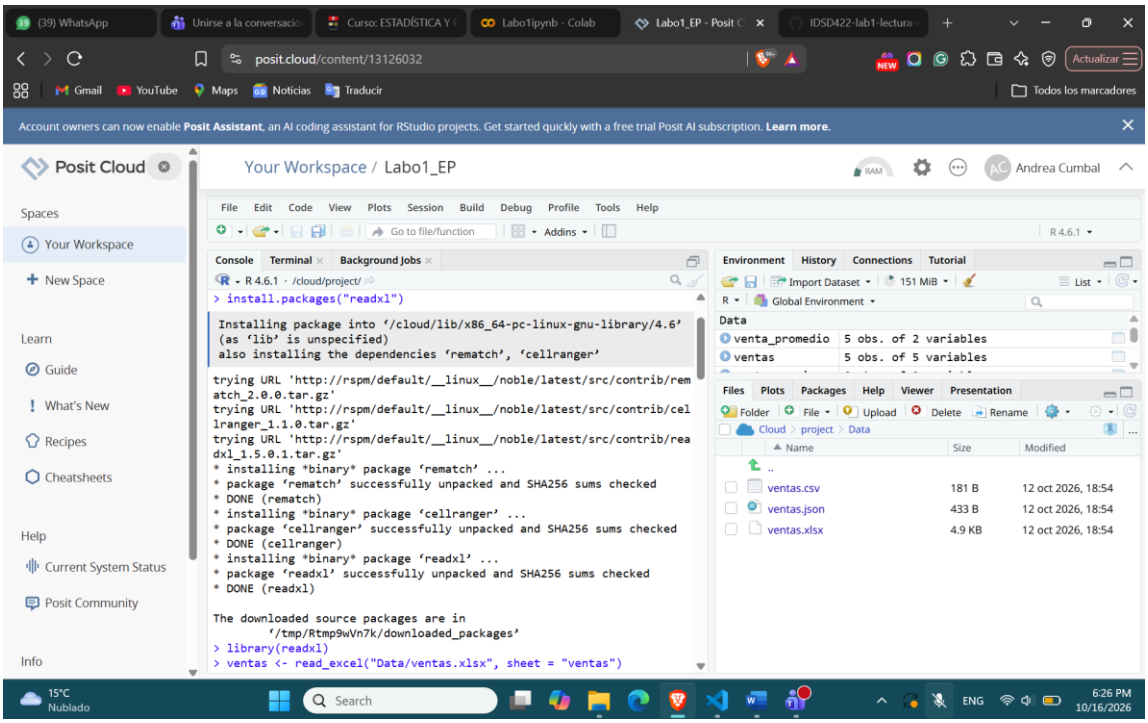


Figura 5. Posit Cloud: carga del conjunto de datos con las librerías de R.

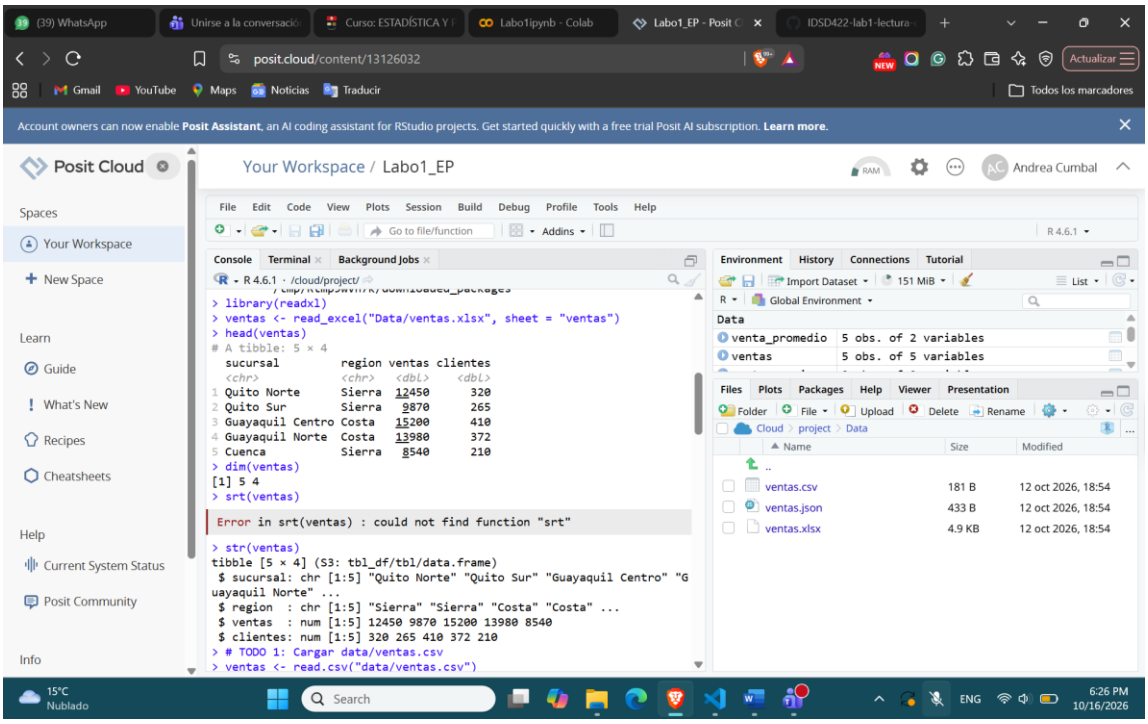


Figura 6. Posit Cloud: primeros registros y una incidencia de ejecución en R.

Anexo D. Evidencias de ejecución

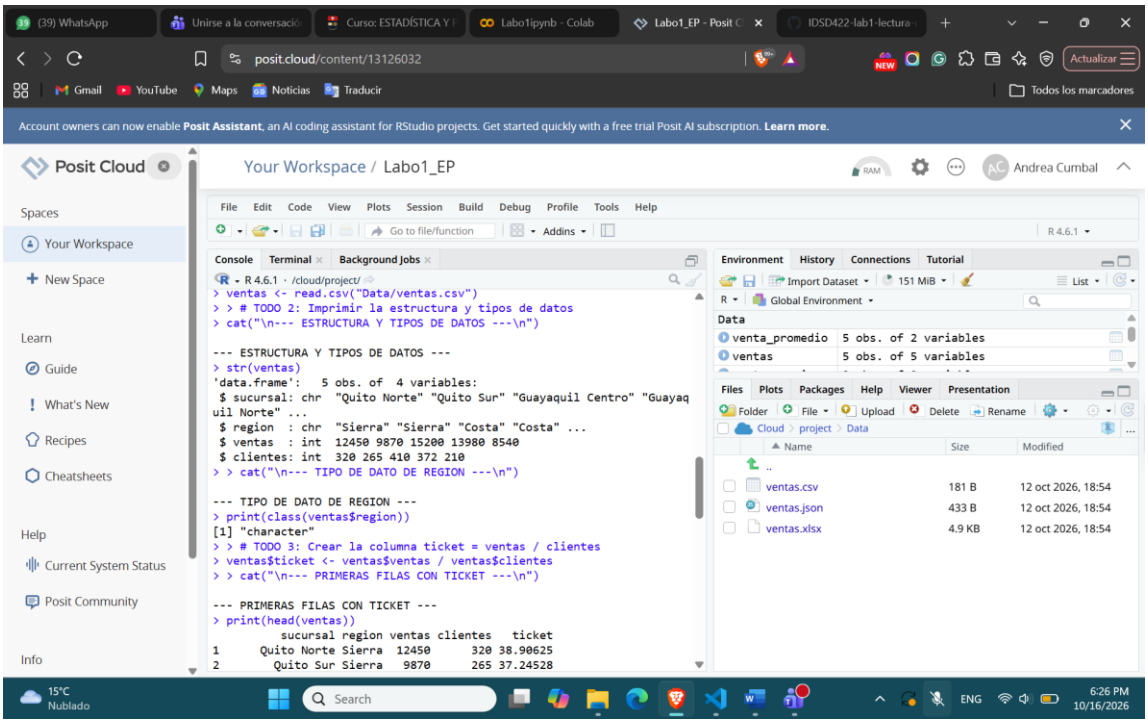


Figura 7. Posit Cloud: inspección de estructura y creación de la columna ticket.

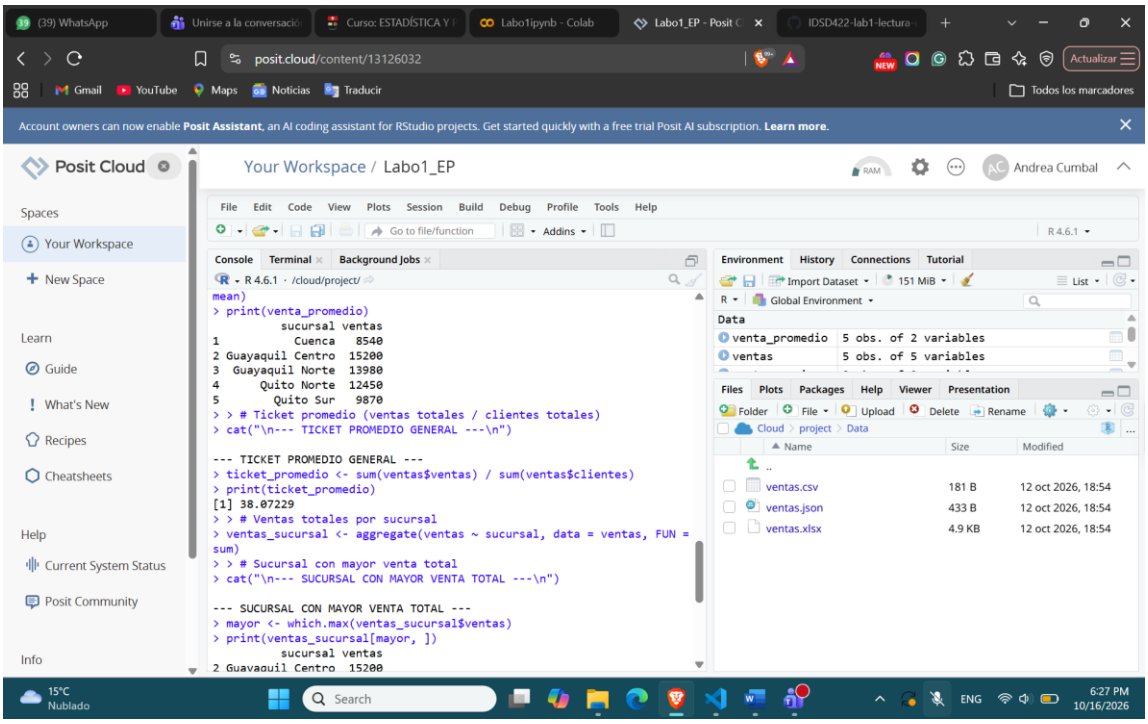


Figura 8. Posit Cloud: promedios e indicadores calculados mediante R.

Anexo E. Evidencias de ejecución

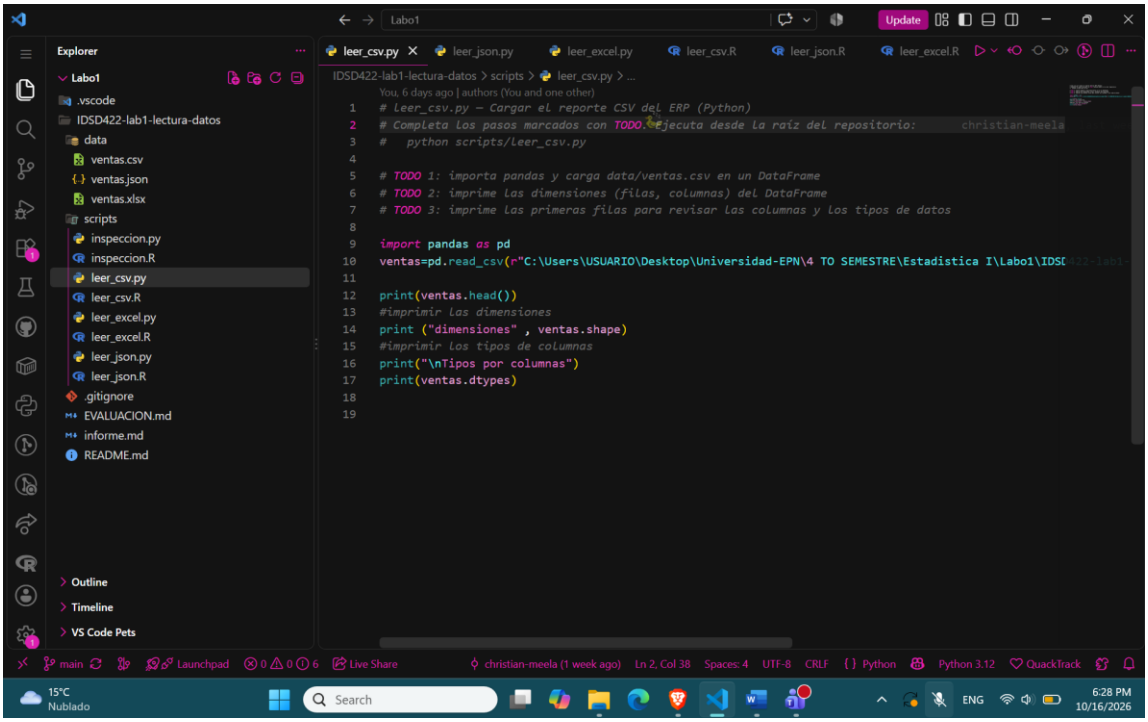


Figura 9. VS Code: script leer_csv.py con el procedimiento de lectura.

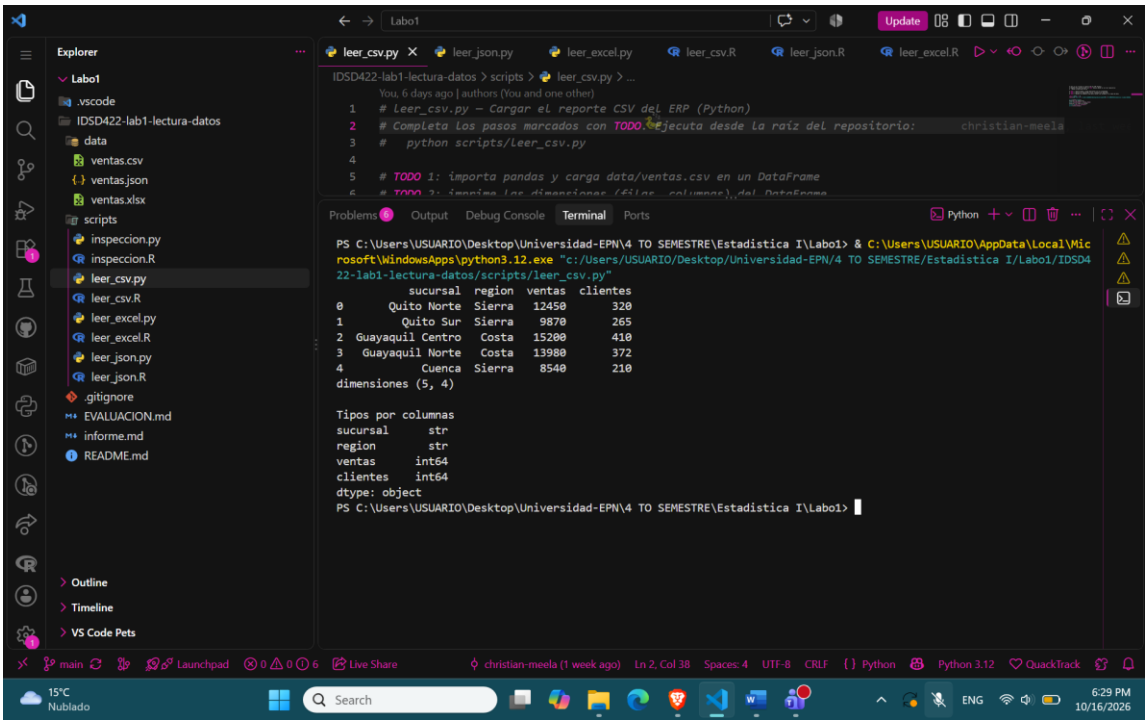


Figura 10. VS Code: resultado de leer_csv.py con cinco filas y cuatro columnas.

Anexo F. Evidencias de ejecución

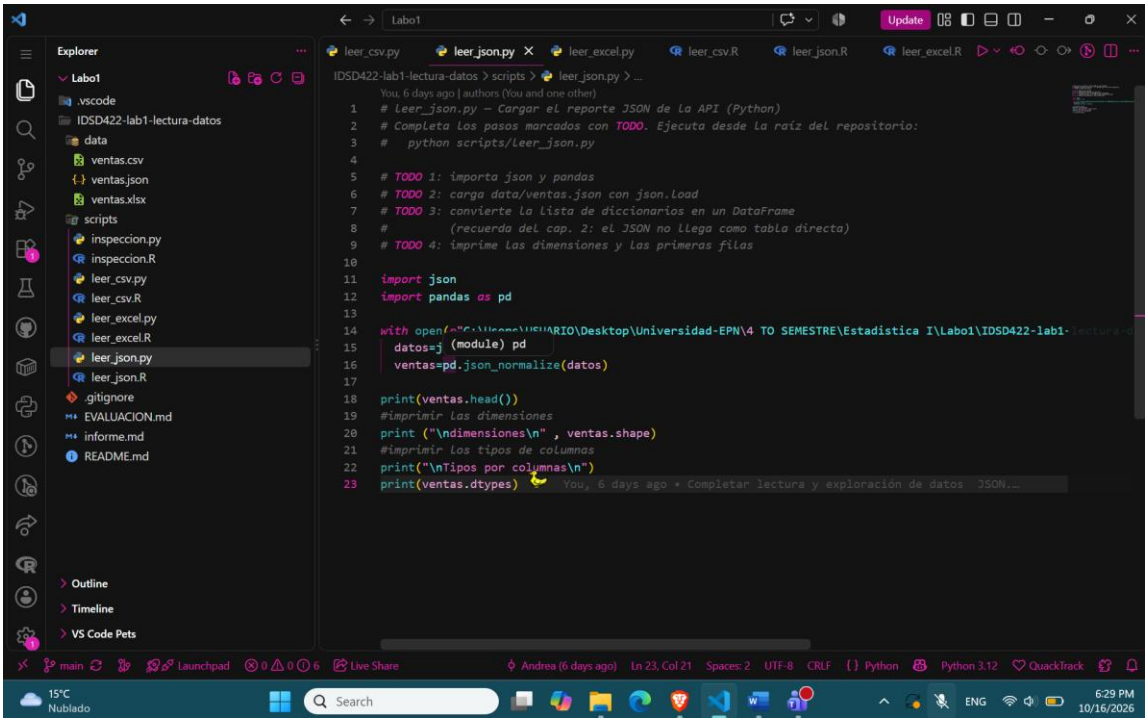


Figura 11. VS Code: script leer_json.py y normalización a una tabla.

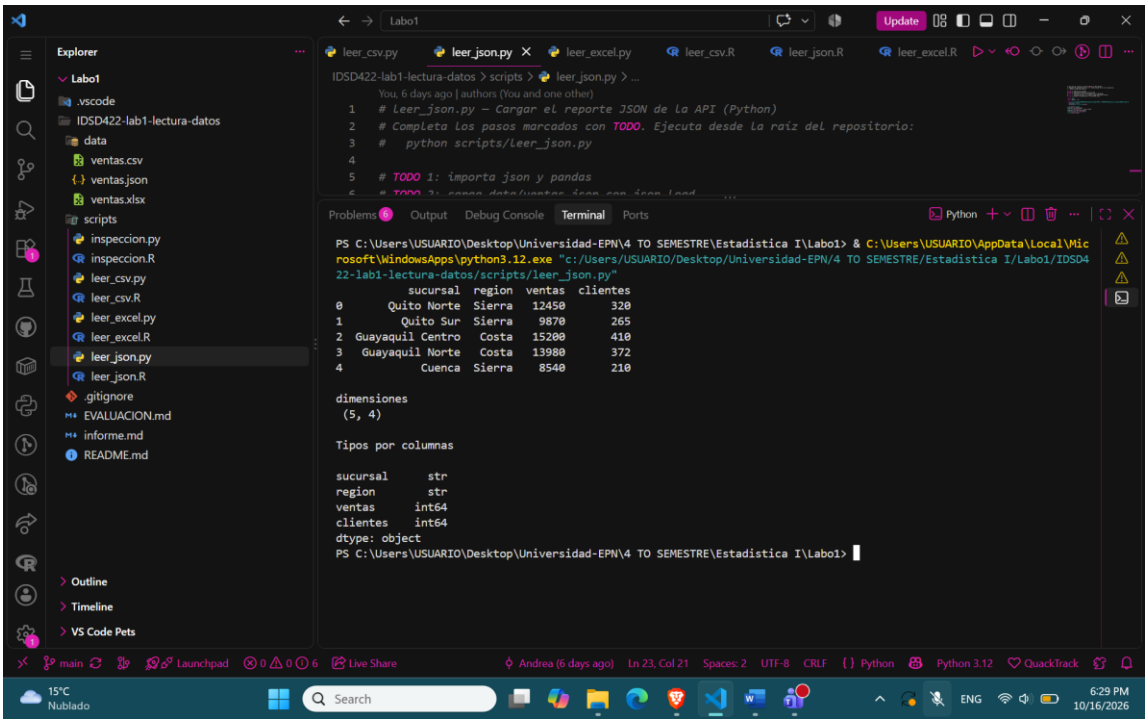


Figura 12. VS Code: resultado de leer_json.py y verificación de tipos.

Anexo G. Evidencias de ejecución

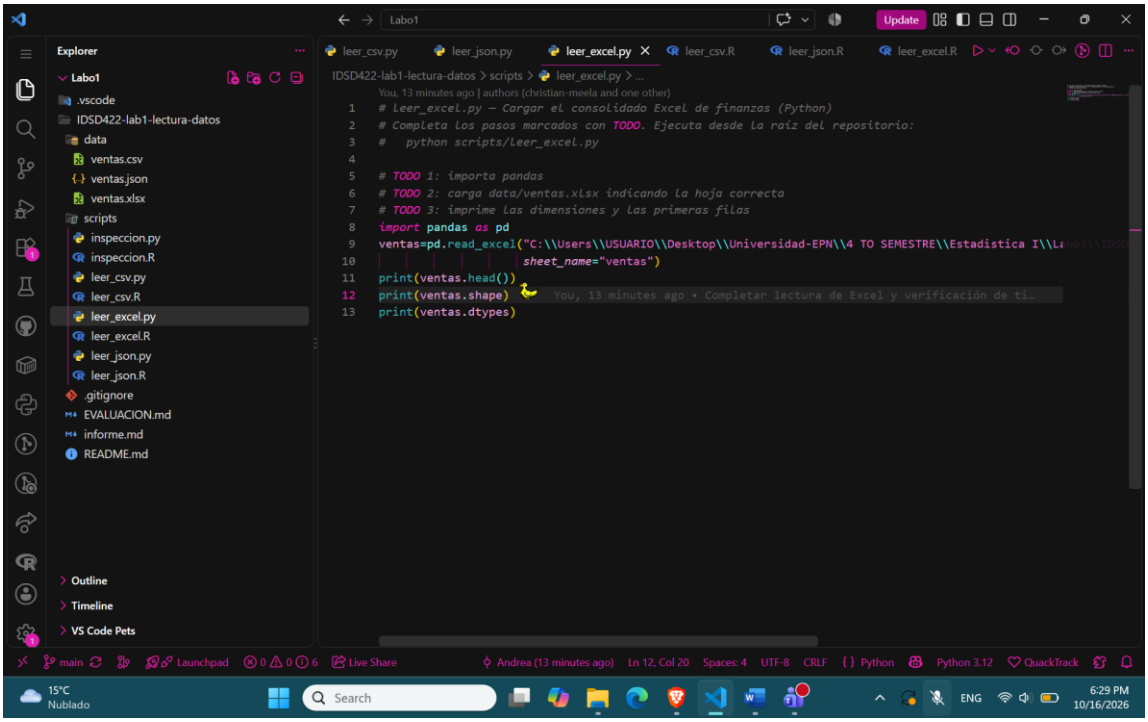


Figura 13. VS Code: código de lectura de Excel en Python.

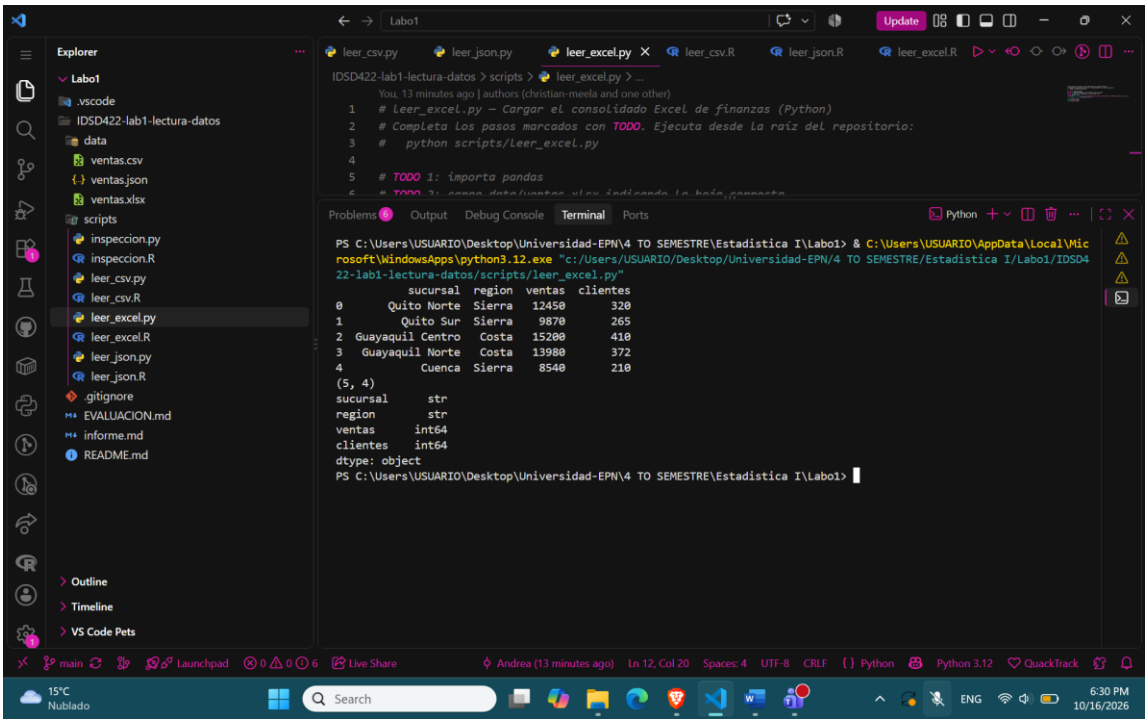


Figura 14. VS Code: resultado de la lectura de Excel en Python.

Anexo H. Evidencias de ejecución

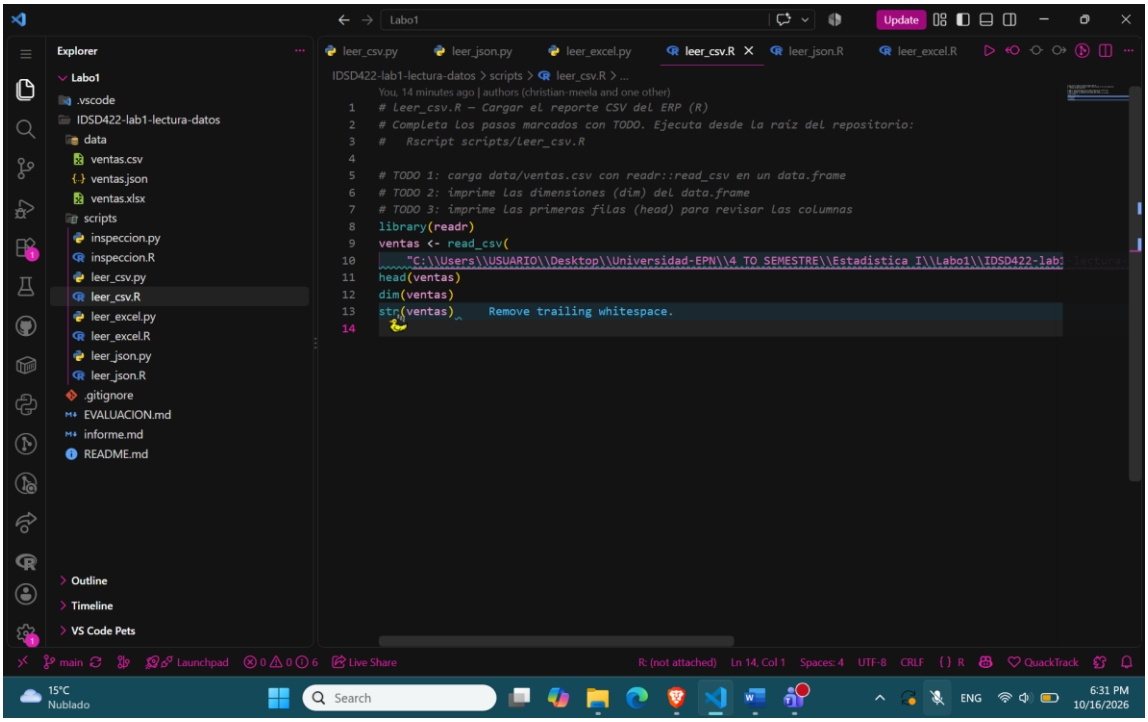


Figura 15. VS Code: código de lectura del CSV en R.

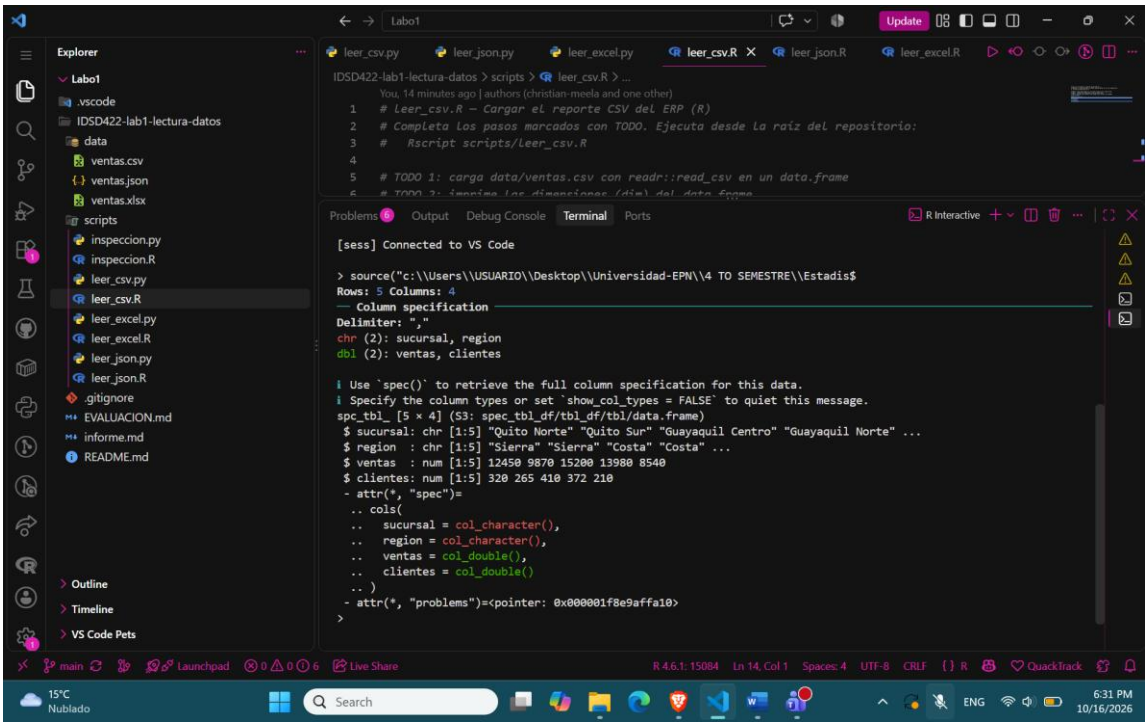


Figura 16. VS Code: ejecución y estructura del CSV mediante R.

Anexo I. Evidencias de ejecución

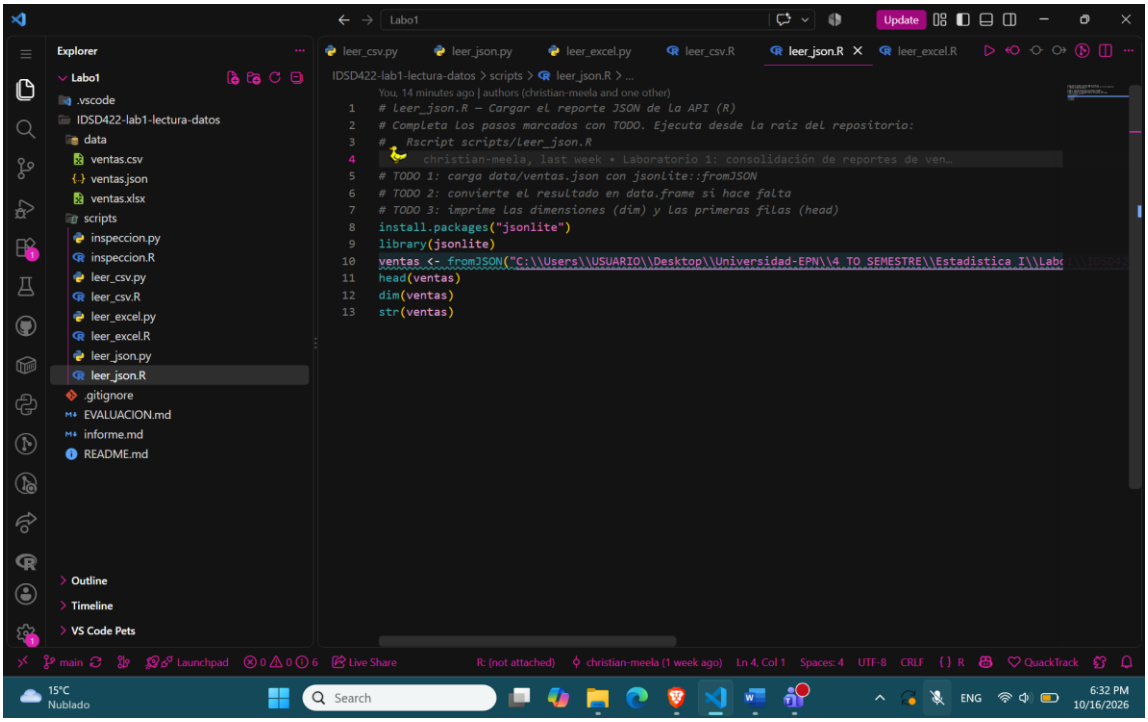


Figura 17. VS Code: script de lectura del archivo JSON en R.

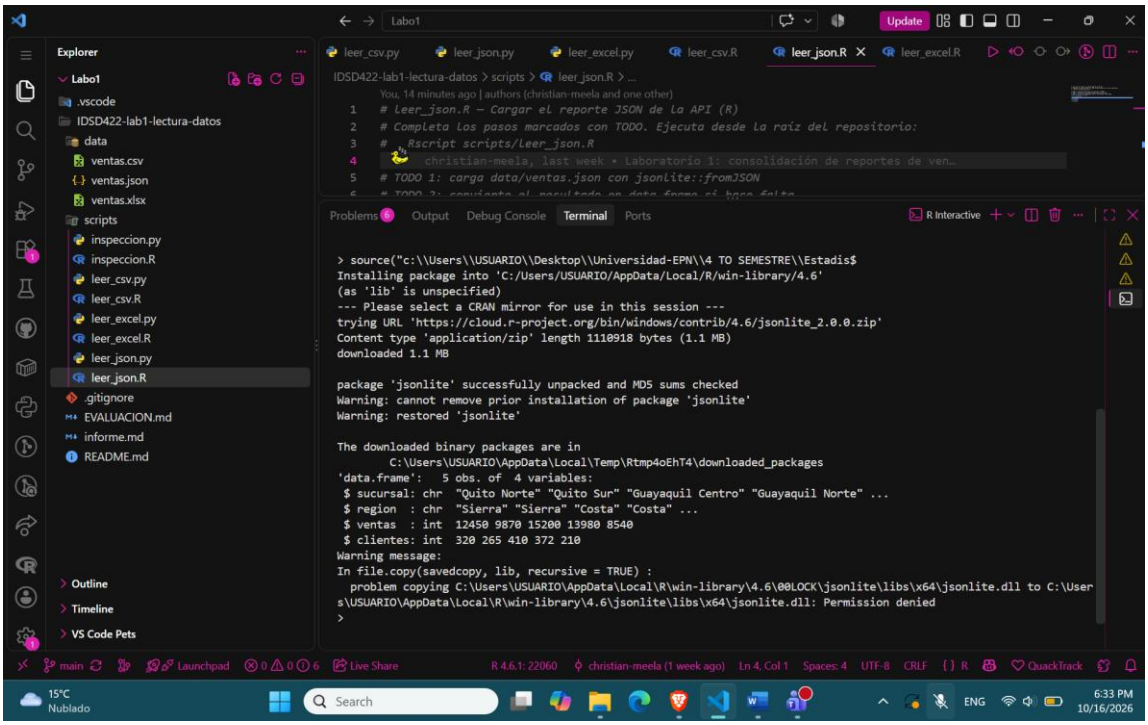


Figura 18. VS Code: ejecución de JSON en R y mensajes del entorno.

Anexo J. Evidencias de ejecución

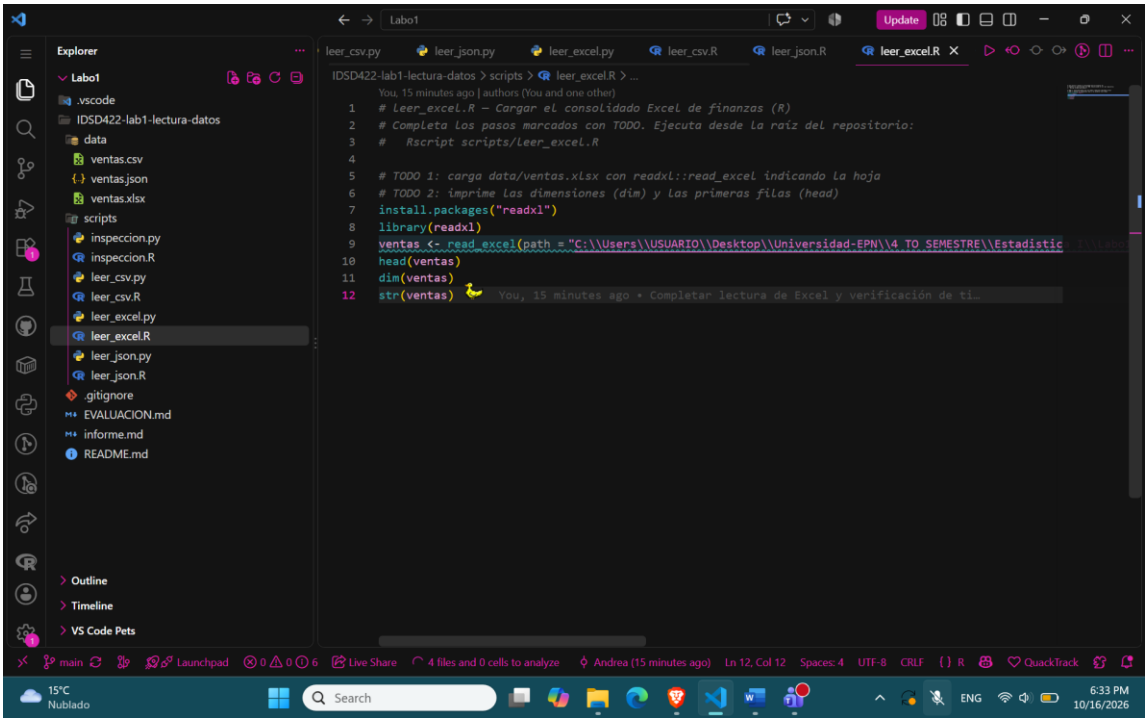


Figura 19. VS Code: script de lectura del archivo Excel en R.

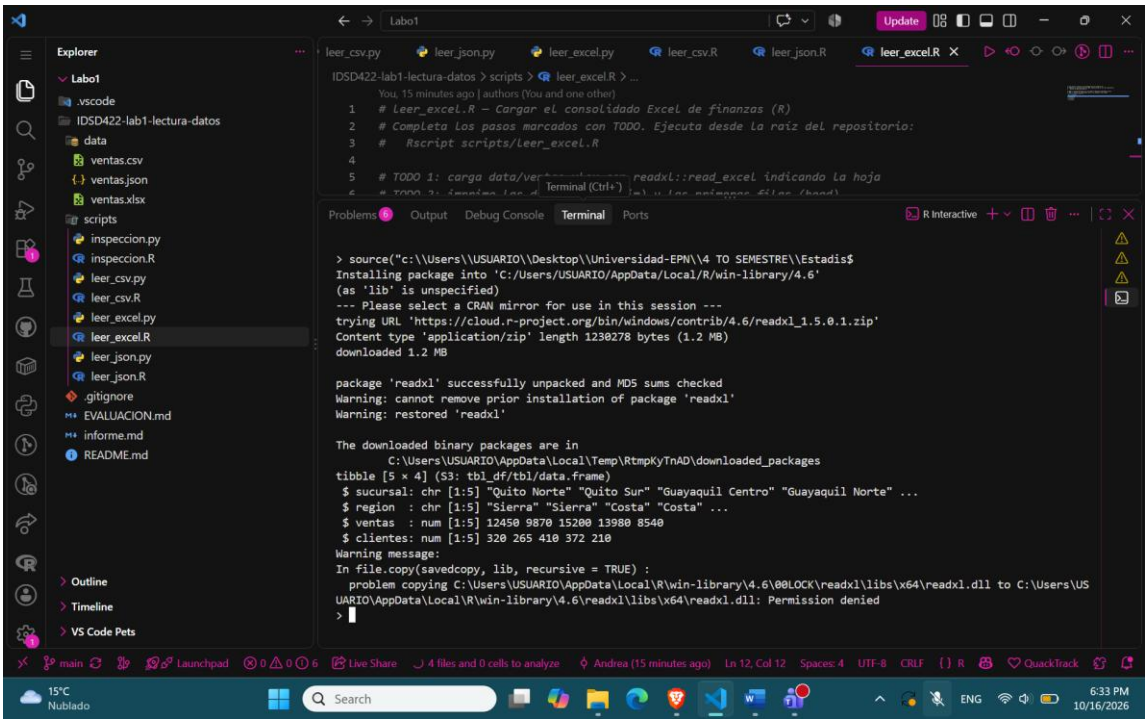


Figura 20. VS Code: ejecución de Excel en R y mensajes de acceso al archivo.

Anexo K. Evidencias de ejecución

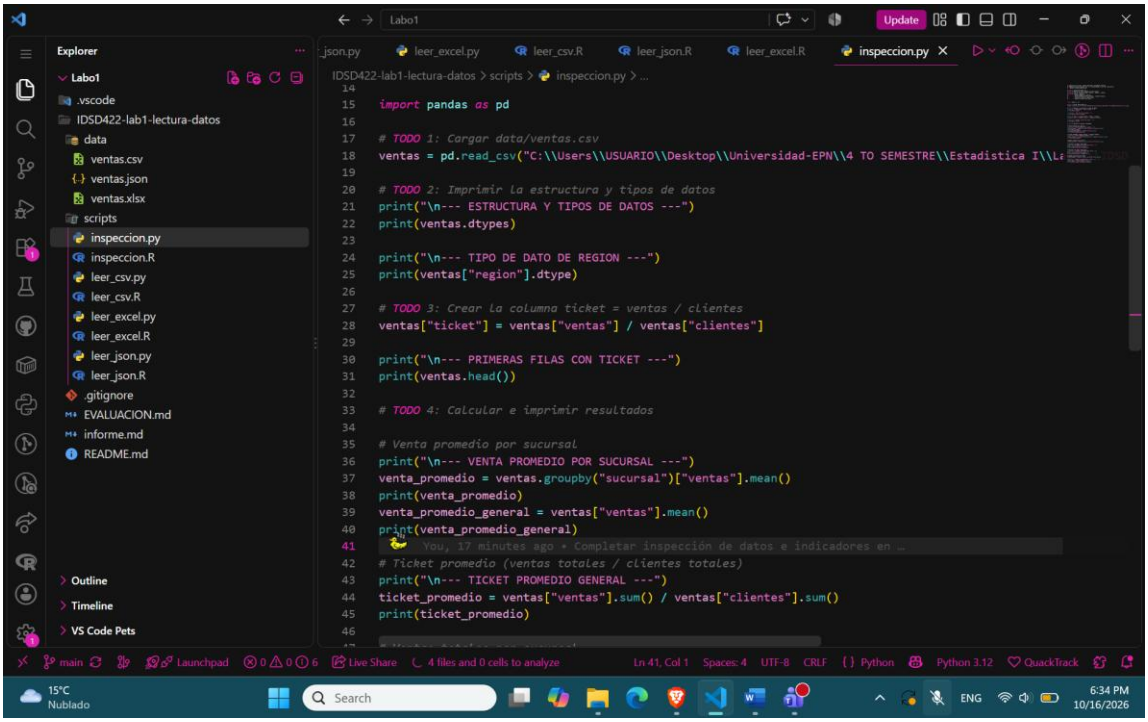


Figura 21. VS Code: código de inspección en Python y operaciones estadísticas.

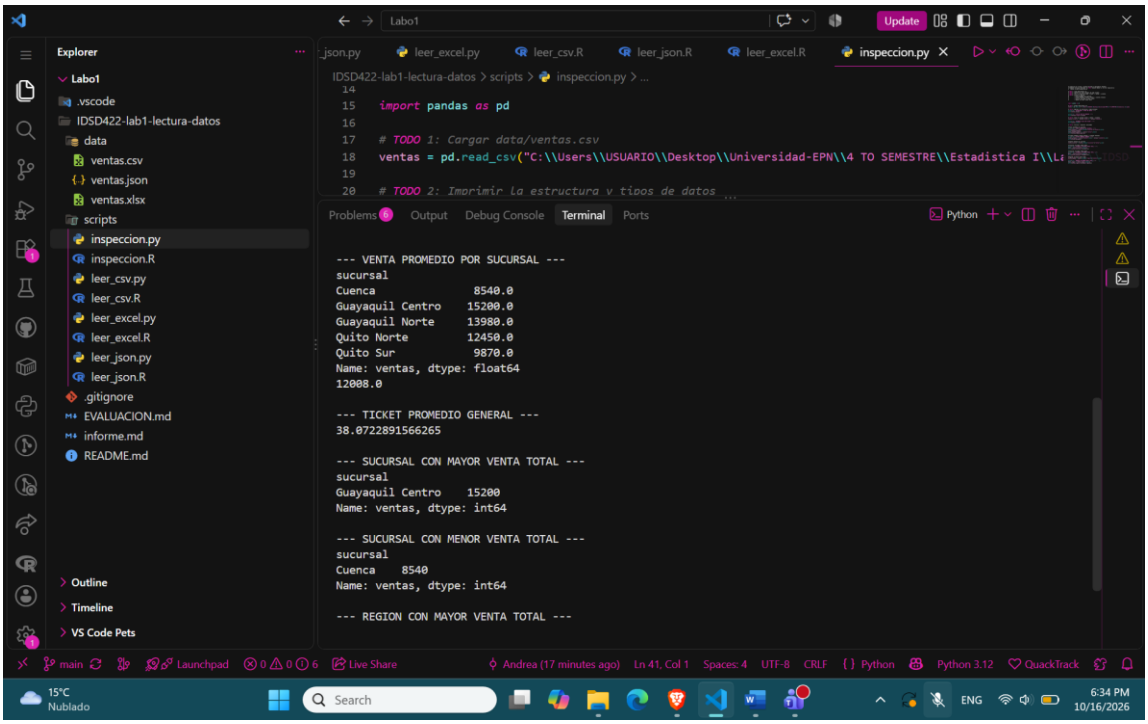


Figura 22. VS Code: salida de indicadores de ventas en Python.

Anexo L. Evidencias de ejecución

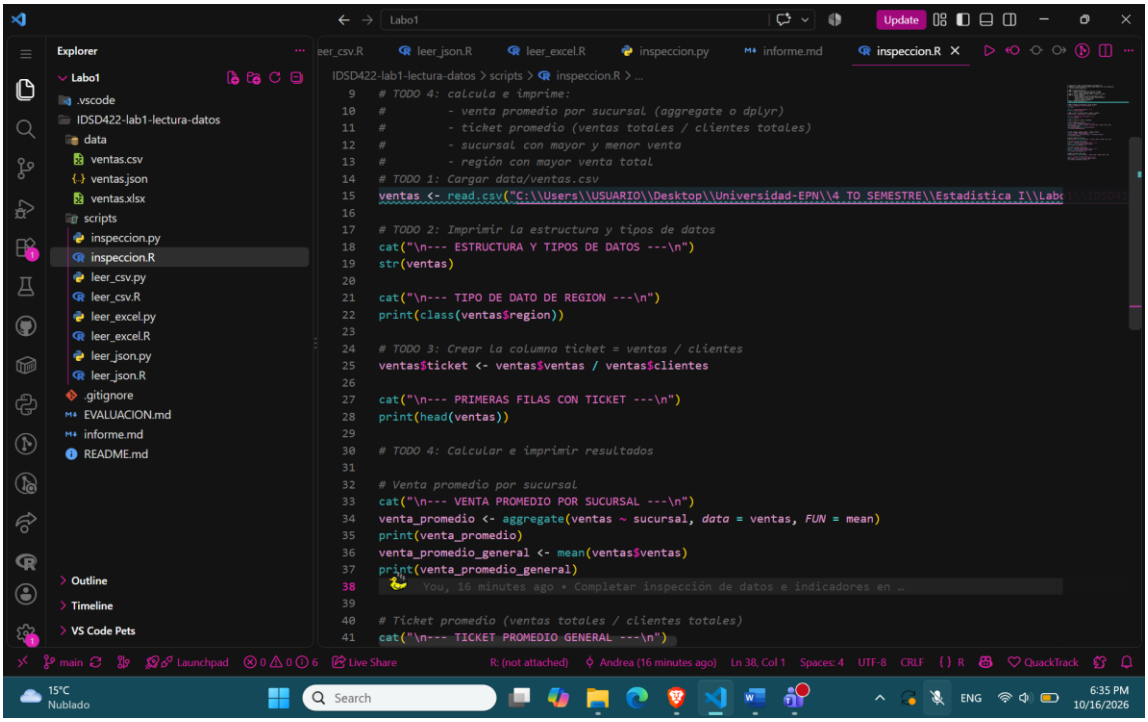


Figura 23. VS Code: código de inspección de ventas mediante R.

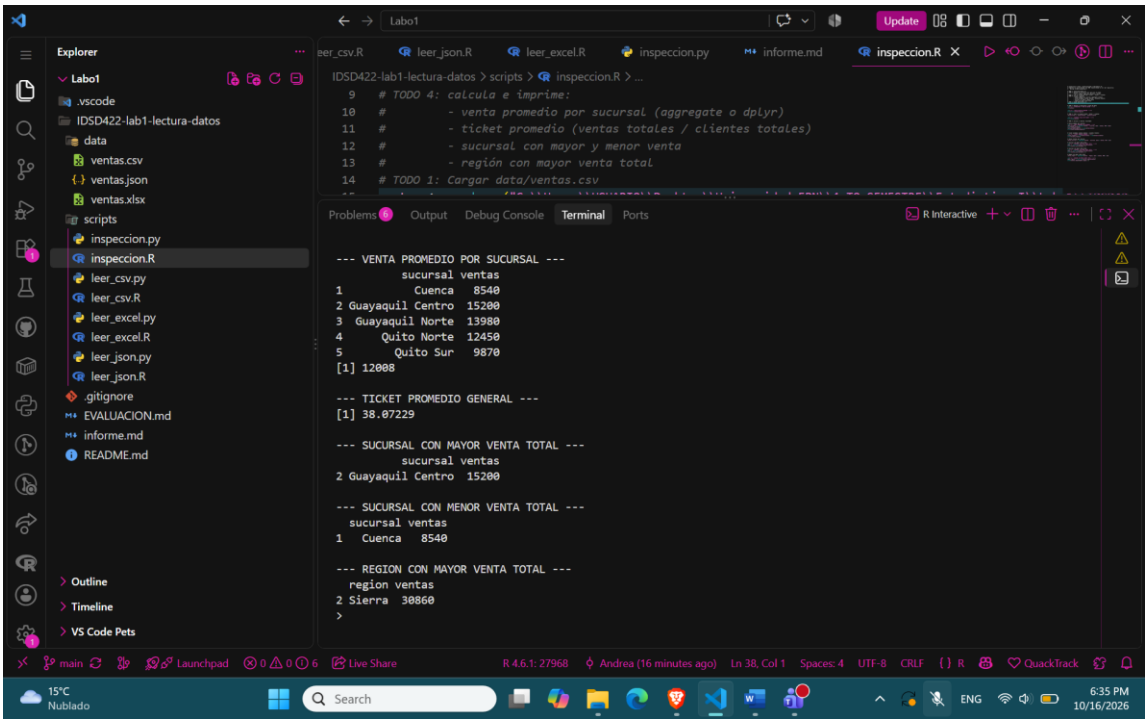


Figura 24. VS Code: resultados de los indicadores y agrupaciones en R.